ChatGPT

Counterfactual Decoding 在 Schema-Abstracted Tool Use 论文中的定义与证据强度评估

A 为什么这类 protocol 必须存在

你的主张本质上是一个“分解假设 + 可复用性断言”：把 function calling 写成 **decision（schema-abstracted）** 与 **grounding（schema-conditioned）** 两层，并声称同一个 decision representation 能跨等价 schema 复用，且 execution feedback 主要应更新 decision posterior，而不是只做 token repair。你在 draft 里也明确把 “counterfactual decoding” 定位为关键证据链和 kill criteria 之一。【filecite【turn2file0】

仅靠“在 schema perturbation 下准确率更高”并不足以支撑这个分解假设。原因是：**鲁棒性提升**可以来自很多与“decision reuse”无关的机制（更强 prompt 模板、更强数据增强、更强 masking、更强 verifier / rerank、甚至只是更会修 JSON）。例如 ICLR [1] 2025 的 Hammer 就明确指出许多 function calling 模型会被命名约定误导、对命名过拟合，并用 data augmentation + function masking 来改善鲁棒性；这类方法即使完全没有“可复用 decision”，也能在 renaming / irrelevant tools 等 stress test 上变强。 [2]

更关键的是：**latent/decision 表征“看起来稳定”不等于“真的表示决策语义”**。NeurIPS 2025 的 “What Do Latent Action Models Actually Learn?” 就专门指出 latent action 可能只是压缩相邻观测差异（甚至差异的原因并不来自控制动作），且会出现过参数化等问题；他们强调需要通过设计期望的不变性/约束来让 latent 更语义化。 [3] 这与你担心 “d_t 只是压缩码”是同一个风险面。换句话说：**如果没有一个“功能性、介入式”的协议去证明 d 可被拿来跨 schema 真实执行，那么 reviewer 完全可以把你的 latent 诊断指标当作可被“做出来”的 self-fulfilling score。**

从“counterfactual”角度看，NeurIPS [4] 2025 的 “Abstract Counterfactuals for Language Model Agents” 也强调：对 LM agent 做 counterfactual 时，token-level counterfactual 往往不够，因为 LM agent 的 action space 隐含在输出字符串里且 token 语义依赖上下文，容易导致 counterfactual 不稳定或无意义；因此他们主张用更高层的 action/interaction 特征来做 counterfactual 推断与评估。 [5] 你的“schema-swap 但 fixed decision”的想法，属于同一类“高层 action/decision 介入”评测。

最后，现实数据也在提醒“schema-bound token”问题不是纸上谈兵：ACL 2025 的 HammerBench 明确报告 parameter name errors 是多轮移动助手 function calling 的显著失败来源之一（这类错误正是 schema-bound 学习最容易暴露的地方）。 [6] 同期 BFCL 系列把 function calling 当作 agentic LLM 核心能力来系统评测，并不断扩展 multi-turn、web search、format sensitivity 等维度。 [7] 这意味着：reviewer 已经习惯问“你到底是在修 tokens，还是在学更稳定的决策对象？”——你需要一个能直接回答这个问题的 protocol。

结论（A 段落的 stance）：这类 protocol 必须存在，因为它是少数能把“decision/grounding 分离 + decision 可复用”从经验性鲁棒性提升中剥离出来、做成可被审稿人检验的核心证据的手段。【filecite【turn2file0】

B 候选定义

下面给出三个“可落地、可写进实验部分”的定义（都避免引入新 fancy 模块，只是把 protocol 的输入/操作/输出说死），并把它们与“latent consistency / clustering”做本质区分。

候选定义一：单向 schema-swap 的 counterfactual decoding

形式化对象

- 环境状态（或单步输入）：s（用户请求 + 对话历史 + 已有工具返回等）
- 工具集合/Schema：T
- 等价变换族：$\mathcal{G}$，对 $g \in \mathcal{G}$，有 $T_B = g(T_A)$
- 你的模型因子分解：decision encoder E，grounding decoder D（对应你 draft 的 $p(d_t \mid s_t, T_t)$ 与 $p(y_t \mid d_t, s_t, T_t)$）。filecite turn2file0

Protocol 定义

对每个样本构造一对等价 schema (T_A, T_B)。执行：

1) **encode under A**：$d_A = E(s, T_A)$
2) **decode under B without re-encoding**（counterfactual step）：

$$y_{A \to B} = D(d_A, s, T_B)$$

3) **评测**：把 ground-truth tool call y_A^* 通过同一个 g 变成 $y_B^* = g(y_A^*)$，比较 $y_{A \to B}$ 与 y_B^* 的 **executability / AST match / success**（取决于 benchmark 的 evaluator；BFCL 就是用 AST 和/或执行后状态来评估）。[8]

优点

- 定义非常清晰：**固定 decision，介入 schema**，直接对应你想证明的 “decision invariant / grounding equivariant”。filecite turn2file0
- 实现代价低：只要你能构造 g 并有 evaluator，就能算出一个 counterfactual decoding score。

缺点（reviewer 会抓的点）

- **可能被“decoder 忽略 d”伪造成功**：如果 D 实际上几乎不看 d，只靠 s, T_B 就能生成 tool call，那 $y_{A \to B}$ 仍可能很高，但这并不能证明你学到了可复用 decision（反而说明 decision 分支是装饰品）。
- **可能是“canonical tool-id”而非语义 decision**：d_A 也许只是某种工具身份/索引的压缩码；若训练时见过类似 g，decoder 学会把该 id 映射到 T_B 中对应工具，就能过测，但这不等价于“schema-abstracted decision representation”。
- **只强力覆盖你的主张 3（跨等价 schema 复用）**：它对主张 1（学 decision 而非 schema-bound tokens）是间接证据；对主张 2（feedback 更新 decision posterior 而非 token repair）几乎不触及，除非你把反馈纳入 protocol（见候选定义三）。

候选定义二：随机化且“未见过”的 schema-swap counterfactual decoding

这是对候选定义一的“加强版”，核心是把最容易被 reviewer 质疑的泄漏路径堵住：**mapping 记忆、id overfit、format confound**。

Protocol 定义（核心仍是 $y_{A \to B} = D(E(s, T_A), s, T_B)$）

不同点在于 g 的构造要满足两条硬约束：

- **(i) g 在评测时随机采样、训练期不可穷举记忆**：例如对 function/parameter 名称做随机字符串重命名、schema key 重排（这类 obfuscation 在 tool-calling 相关工作里已被广泛采用来避免 regurgitation/过拟合；ToolRM/FC-RewardBench 明确写到用随机字符串替换函数名/参数名并重排 schema keys）。 [9]
- **(ii) schema 结构扰动覆盖“命名噪声”与“排列噪声”**：可以对照 RoTBench 那类噪声操作（字符插入/删除、name reversal、name swapping 等），它们本质上就是更工业化的“argument/tool name corruption” stress test。 [10]

建议的 score 分解（为了让 reviewer 不好挑刺）

- **CF-ExecAcc / CF-ASTAcc**：$y_{A\to B}$ 在 T_B 下可执行且语义正确的比例。 [11]
- **CF-Gap（关键）**：再算一个“正常在 B 下推理”的结果

$$y_{B\to B} = D(E(s, T_B), s, T_B)$$

用差值 $\text{CF-Gap} = \text{Acc}(y_{B\to B}) - \text{Acc}(y_{A\to B})$ 衡量“不重编码到底损失多少”。如果你声称 E 学到 schema-invariant decision，那么 CF-Gap 应该小；否则 reviewer 会说：你的 decision 仍强依赖 schema，离“representation reuse”很远。filecite turn2file0

优点

- 更接近“不可作弊”的核心证据：随机化重命名 + key 重排能显著降低“记忆 mapping / 依赖顺序索引”的解释空间。 [12]
- 对主张 1 的支撑更强：如果在严重命名扰动下仍能用 d_A 成功 grounding，reviewer 很难再说你只是学了 schema-bound token 模式（尤其当你同时引用 Hammer 指出的 naming overfit 风险）。 [2]

缺点

- 更容易引入“任务难度混淆”：模型失败可能是因为读不懂 tool description、或 benchmark evaluator 本身噪声，而不一定是 decision 不可复用。
- 对等价性的定义更苛刻：一旦你的 g 里包含“不可逆 reshape”或让 description 语义漂移，reviewer 会说你测的不是 equivalent schema，而是 distribution shift。

候选定义三：把 execution feedback 纳入的 counterfactual decoding

这是唯一一个能把你的主张 2（feedback 更新 decision posterior）拉到 protocol 核心位置的版本。

核心思想

你想证明的不是“模型在 schema B 下能做对”，而是：**同一条反馈驱动的 decision posterior 更新能跨等价 schema 复用**。这就要求 protocol 里出现 feedback f。

Protocol 定义（一个 reviewer 友好的写法）

构造两套等价 schema：$T_A, T_B = g(T_A)$。执行：

1）在 T_A 下先产生一个 action（可故意让它失败以触发 feedback），得到执行反馈 f（例如：executable flag、error type、或工具返回摘要——你 draft 已提出分层 feedback budget 以避免 teacher leakage）。filecite turn2file0

2) 用同等信息预算的反馈条件后验（或其近似）更新 decision：

$$d_A^{post} \sim q(d \mid s, f)$$

3) **counterfactual step**：保持这个 d_A^{post} 不变，切换到 T_B 做 grounding：

$$y_{A\to B}^{post} = D(d_A^{post}, s, T_B)$$

4) 评测 $y_{A\to B}^{post}$ 的正确性，并与两类强 baseline 做同预算对照：
- **token-level hindsight/self-distillation**：SDPO 明确是“把 feedback tokenized 后，令 feedback-conditioned self-teacher 的 next-token 分布蒸馏回 policy”，本质更新的是 token posterior。[13]
- **next-state + OPD 系列**：OpenClaw-RL 的摘要写得非常直白：从 next-state signal 中提取 evaluative signals（PRM 标量奖励）与 directive signals，并通过 Hindsight-Guided On-Policy Distillation 给出 **token-level directional advantage supervision**。[14]

优点

- 这是唯一能让 reviewer “没办法把你归约成 token repair”的 protocol：你不是问“有没有修好输出”，而是问“**后验更新是否发生在 decision 层，并且可跨 schema 迁移**”。（反过来说，如果你做不出这一步，你的主张 2 会非常危险。）

缺点（最容易被攻击）

- **teacher leakage / information asymmetry**：只要 $q(d \mid s, f)$ 看到了比 token baseline 更多的信息（比如完整 tool output、甚至 ground truth），protocol 立刻失去说服力。你必须像 SDPO 那样明确 feedback 的形式与预算，并让所有 baseline 用同预算信息。[15]
- **评测链条更复杂、更难复现**：reviewer 会要求你说明 feedback 抽取、摘要压缩、错误类型结构化等细节，否则会被认为是“手工工程 + hidden prompt”。

它与 latent consistency / clustering 的本质区别

这是你必须在论文里用几句话钉死的点，否则 reviewer 会说你只是“换一个 latent 指标”。

- latent consistency / clustering 基本是 **观测性（observational）**：比较 $E(s, T_A)$ 与 $E(s, T_B)$ 的距离、聚类纯度、互信息等。它可以在两种“假阳性”下看起来很好：
  1) encoder 输出常量 d（一致性完美，但完全没信息）；
  2) decoder 基本不看 d，导致“d 长什么样”与实际行为无关。
- counterfactual decoding 是 **介入式（interventional）且功能性（functional）**：你做的是 $do(T = T_B)$ 的干预，同时固定 d，看最终可执行行为是否仍正确（并且应该附带 $do(d = \text{shuffle})$ 之类的反事实对照，见下文推荐定义）。这种测试直接检验“d 是否是可被复用的决策充要信息 / 是否真的驱动 grounding”，而不是检验“embedding 是否看起来对齐”。

C 最推荐的定义

如果你的目标是“最公平、最不容易被 reviewer 质疑”，我推荐把 **候选定义二**作为主定义（主图/主表的 counterfactual decoding score），并把两个“不可缺少的反事实对照”写进 protocol 本身，否则它会被轻易拆穿。

推荐定义：未见过随机化 schema-swap + d-介入对照

正式定义（建议原封不动写进 paper）

对每个样本 (s, T_A, y_A^{*})，从随机种子 ω 采样一个等价变换 $g_\omega \in \mathcal{G}$，得到 $T_B = g_\omega(T_A)$ 与 $y_B^{*} = g_\omega(y_A^{*})$。令模型参数固定不变，温度/解码策略固定不变。

- counterfactual decoding 输出：

$$y_{A\to B} = D(E(s, T_A), s, T_B)$$

- **d-介入对照 1（shuffle control）**：在 batch 内随机置换 decision，使

$$\tilde{d}_A = \pi(d_A), \quad \tilde{y}_{A\to B} = D(\tilde{d}_A, s, T_B)$$

  要求 $\mathrm{Acc}(\tilde{y}_{A\to B})$ 显著低于 $\mathrm{Acc}(y_{A\to B})$，否则说明 decoder 不依赖 decision，protocol 对主张不构成证据。
- **d-介入对照 2（null control）**：令 $d = \bar{d}$（例如全零或最频繁 code），同样要求 accuracy 显著下降。

为什么这是“最不容易被 reviewer 质疑”的版本

- 你用随机字符串重命名与 key 重排堵住 “记忆 mapping / 顺序索引” 的解释空间（这类 obfuscation 在 tool-calling work 里是被认可的做法，例如 ToolRM/FC-RewardBench 直接把它作为防止 regurgitation/过拟合的手段，并在消融里显示去掉 obfuscation 明显损害效果）。 [9]
- 你把 “d 是否真的在驱动 grounding” 变成一个**可复现、可否证**的 check（shuffle/null control），让 reviewer 很难用一句 “decoder might ignore the latent” 把你打回去。
- 你只干预 schema 输入 T，不允许“换 grounding head”当作 counterfactual step（你 draft 里提到可替换 grounding 头或工具上下文，但从审稿角度，替换头会引入额外自由度：reviewer 会问你是不是用 per-schema head 在做隐式适配）。filecite turn2file0
- 你还有 CF-Gap 作为补充：即便 reviewer 不认同 latent 的解释，他们也必须面对一个硬事实——“不重编码的跨 schema grounding 损失/不损失多少”。

我对“它是否足够强”的判断

- **对主张 3（representation reuse across equivalent schema）**：只要你做到上述随机化 + d-介入对照，它就是强证据（接近“功能性可复用”的操作化定义）。
- **对主张 1（学 schema-abstracted decision 而非 schema-bound tokens）**：它是强但仍可被挑战的证据。挑战点会是：“你的 d 可能表示 canonical tool identity，而不是抽象语义 decision。”要进一步堵这个口，最有效的是在 g_ω 中加入强命名扰动（随机字符串）并随机插入大量 irrelevant tools（扩大 tool pool），这与 Hammer 指出的 overfit 风险对齐。 [2]
- **对主张 2（feedback 更新 decision posterior）**：推荐定义本身不够，你需要把候选定义三作为“同一个 protocol 的带 feedback 版本”来补齐，否则 reviewer 会把你的贡献归类为“robustness via augmentation + latent regularization”，而不是“posterior refinement”。SDPO 与 OpenClaw-RL 已经把“feedback → token posterior distillation/advantage supervision”这条路讲得很清楚，你必须证明你更新的是 decision 层且可迁移，否则会被直接对标掉。 [15]

D 具体实验步骤

这里我按“写进论文也不会被说含糊”的粒度给出步骤，重点是把 protocol 的可复现性钉死。

数据与 evaluator 选择的最低要求

1) **优先选可自动验真的 evaluator**。BFCL 论文页明确强调他们用 AST 等方式可以扩展到大量 functions，并且包含 multi-step/multi-turn 评估。 [11]
2) **避免把 BFCL multi-turn 原始套件当作唯一证据**：EigenData 对 BFCL multi-turn base suite 的审计给出了

非常尖锐的结论：函数 schema 错误、实现错误、以及轨迹/评估逻辑错误会显著损害可靠性，报告中甚至给出在 200 条 multi-turn 条目中大量受影响条目的统计。 [16]
这意味着：如果你把 counterfactual decoding 的关键结论押在 BFCL-v3 multi-turn 上，而没有说明你用的是修复版本/过滤版本/或更可靠的子集，reviewer 可以直接质疑你在噪声基准上做了过拟合结论。

Protocol 实施步骤

步骤一：定义等价变换族 $\mathcal{G}$
你 draft 已把可接受的等价变换限制在：tool renaming、argument renaming、doc/description paraphrase、少量可逆 argument reshaping。filecite turn2file0
我建议在 protocol 文字里把它写成“必须可构造双射映射（bijection）并能把 ground-truth call 映射过去”，否则 reviewer 会追问“等价性谁说了算”。

步骤二：实现随机化变换 g_ω（推荐至少包含两类随机化）

- **随机字符串重命名 + schema key 重排**：直接参考 ToolRM/FC-RewardBench 的描述——用随机字符串替换 function/parameter 名，并重排 schema 中 key 的顺序。 [9]
- **噪声式命名扰动（可选但很加分）**：参考 RoTBench 的噪声操作，如字符插入/删除、name reversal、name swapping，并按噪声强度分层（Slight/Medium/Heavy）。 [10]
  这让你的 protocol 看起来不是“自创玩具变换”，而是与既有鲁棒性评测范式对齐。

步骤三：对每个样本构造 (T_A, T_B, y_B^*)

- T_A：原 schema（tool list + descriptions + argument specs）。
- $T_B = g_\omega(T_A)$。
- $y_B^* = g_\omega(y_A^*)$。
- 还要做一个很容易被忽略但 reviewer 会抓的 sanity check：**用户文本里是否显式出现 tool/parameter 名称**。若出现，单纯 renaming tool list 会破坏任务语义；要么过滤掉这类样本，要么同时对用户文本做一致替换（但这已经改变了 s，你需要在论文里解释这是否仍算“同一 decision”）。

步骤四：执行三次解码（同解码超参）

- 正常 A：$d_A = E(s, T_A)$，$y_A = D(d_A, s, T_A)$。
- counterfactual A→B：$y_{A\to B} = D(d_A, s, T_B)$。
- 正常 B：$d_B = E(s, T_B)$，$y_{B\to B} = D(d_B, s, T_B)$（用于 CF-Gap）。

步骤五：执行两类 d-介入对照

- shuffle：$\tilde{y}_{A\to B} = D(\pi(d_A), s, T_B)$。
- null：$y^{null} = D(\bar{d}, s, T_B)$。
  要求这两者显著下降，否则 counterfactual decoding 分数不能被解读为“decision reuse”。

步骤六：评测与报告方式

- 主指标：CF-ExecAcc / CF-ASTAcc（按 evaluator）、以及 CF-Gap。 [11]
- 同时报告“format sensitivity 相关控制变量”：BFCL-v4 的 format sensitivity 博客显示仅更换 return format / function doc format 都会系统性影响准确率（例如 JSON / Python / XML 的差异），所以你的 schema perturbation 必须避免把“格式变化”混进“语义等价变换”，否则 reviewer 会说你测到的是 prompt 格式效应而不是 representation reuse。 [17]

带 feedback 的扩展步骤（用于把主张 2 拉进证据链）

若你要让 “feedback 更新 decision posterior” 成为主张而不是口号，最少需要在同一个 protocol 下做一次：

- 在 T_A 下执行得到反馈 f，按你 draft 的分层预算（Level A/B/C）构造后验更新。【filecite【turn2file0】
- 用同预算信息，让 token-level hindsight 方法（SDPO 风格 self-teacher distillation、或 OpenClaw-RL 的 OPD 风格 directive extraction）做对照，因为它们都明确是把反馈转成 token 级学习信号；你要证明你的收益不是“更会修 tokens”。 [15]

E 可能的失败模式

下面这些失败模式都不是“工程小坑”，而是 reviewer 最喜欢用来否定论文主张的逻辑漏洞。

decision 被 decoder 忽略（最致命）
你会看到 counterfactual decoding 分数很高、latent consistency 也很高，但 shuffle/null control 不下降。这意味着你的两层分解是形式存在、功能不存在——模型仍然在做 “直接从 s, T 生成 tool call”。在这种情况下，counterfactual decoding 不能支撑“decision representation 可复用”，因为实际上根本没有 decision 在起作用。

decision 只是 canonical tool id（而非 schema-abstracted 语义）
在没有强随机化的情况下（尤其是仅做简单 renaming），d 只要能稳定指向某个“工具身份”，decoder 就能把它落到 schema B 的对应工具上。这会造成一种“看似跨 schema 复用”的假象。Hammer 已经把 naming overfit 当作核心问题来处理，ToolRM/FC-RewardBench 也显示去掉 obfuscation 会显著掉分；这意味着 reviewer 已有现成论据来质疑你是否真的学到了语义 invariant，而不是学到了 id 对齐。 [18]

等价变换族定义不严谨，导致 protocol 可被质疑为“换任务”
一旦你把不可逆 argument reshape、或改变工具可表达能力的变换塞进 $\mathcal{G}$，reviewer 会说：你不是在测“同一个 decision 在不同 schema 下是否可复用”，而是在测 distribution shift。你 draft 里已经强调只承认少量可逆 reshaping，这条边界最好写成硬约束。【filecite【turn2file0】

benchmark evaluator 的噪声吞没效应
如果你用 BFCL-v3 multi-turn 做关键结论，EigenData 关于 schema/implementation/trajectory errors 的审计会让 reviewer 合理怀疑你的差异是否来自 evaluator bug 或 rigid matching。 [19]
这不是说 BFCL 不能用，而是说：你必须在论文里交代你如何处理 evaluator 风险（例如用修复版/过滤版/或把 multi-turn 结论放在附录并用更可靠子集做主表）。

format sensitivity 混淆成“schema variation”
BFCL-v4 的分析显示不同 return format（JSON/Python/XML）与 function doc format 会显著影响准确率；如果你的 “schema B” 同时改变了输出格式或工具文档格式，你的 counterfactual decoding 失败/成功都可能被解释为格式效应而非 decision reuse。 [17]

带 feedback 版本被质疑为 teacher leakage
这是主张 2 的最大雷区。SDPO 的论证路径很清楚：把 rich textual feedback 变成 dense learning signal，通过 self-teacher 的反馈条件分布蒸馏回 policy。 [13]
你如果用更强的 f（比如完整工具输出甚至 ground truth）去构造 $q(d \mid s, f)$，reviewer 会说你用信息优势换来了提升，而不是“更新对象（decision posterior）不同”带来的提升。OpenClaw-RL 同样把 directive signal 从 next-state 中提取出来做 OPD，并明确是 token-level directional advantage supervision；你必须在信息预算上与这类方法对齐。 [14]

F 如果这个 protocol 做不出来，论文主张会怎么塌

这里我直说 reviewer 视角下的“塌法”，对应你三条核心主张各自的脆弱点。

主张 3（跨等价 schema 复用）会直接失去可操作化证据
没有 counterfactual decoding，你最多只能说“模型在另一套 schema 上也能做对”——但这并不等价于“同一个 decision representation 被复用”。reviewer 会要求你证明“复用”的含义，而不是“泛化”的含义。你 draft 也把 counterfactual decoding 失败列为 kill criteria，这说明你自己也承认它是证据链的关键环。
filecite turn2file0

主张 1（学 schema-abstracted decision 而非 schema-bound tokens）会被归约为“更强的数据增强/更强鲁棒性 recipe”
Hammer 的叙事已经把“命名过拟合导致跨基准不稳定”讲清楚了，并且给出了数据增强 + masking 的解决方案。[2]
ToolRM/FC-RewardBench 还展示了用 obfuscation（随机化函数名/参数名+重排 keys）能显著改变模型行为与性能。[9]
在这样的相关工作背景下，如果你没有一个能证明“decision/grounding 分离带来的可复用性”的硬协议，reviewer 把你判成 “Hammer/obfuscation 风格工作的变体 + 一些 latent regularization”是非常自然的。

主张 2（feedback 更新 decision posterior，而非 token repair）会被 SDPO / OpenClaw-RL 直接压过叙事高度
SDPO 的核心句子几乎就是：“把 tokenized feedback 转成 dense learning signal，用 feedback-conditioned self-teacher 的 next-token 分布蒸馏回 policy”。[13]
OpenClaw-RL 更明确：directive signals 通过 OPD 变成 token-level directional advantage supervision。[14]
如果你没有“带 feedback 的 counterfactual decoding”去证明：**同样预算的反馈下，你更新的是 decision posterior 且该更新能跨 schema 迁移**，那么 reviewer 会认为你只是在另一个空间做了 hindsight/token repair 的等价变体，而不足以支撑“更新对象不同”的核心主张。

最终的整体塌缩形态
没有 counterfactual decoding（尤其是带 d-介入对照的版本），你的论文很可能被重新描述为：
“在 function calling 上做了一套训练/对齐 trick，使模型在 renaming、format variation、irrelevant tools 等设置下更稳。”
这当然可能仍是一篇可接受的工程论文，但它不再能自洽地承载你想要的三条原则性主张（decision abstraction、posterior refinement、representation reuse）。

```
官方/原始页面与论文链接（便于你直接在文稿中引用）
- CoLA (ICML 2025, PMLR): https://proceedings.mlr.press/v267/jia25e.html
- What Do Latent Action Models Actually Learn? (NeurIPS 2025, OpenReview PDF): https://
openreview.net/pdf?id=DQMjemrVhe
- Abstract Counterfactuals for Language Model Agents (NeurIPS 2025, OpenReview): https://
openreview.net/forum?id=ifMZw5fm7K
- BFCL (ICML 2025 poster page): https://icml.cc/virtual/2025/poster/46593
- BFCL v4 leaderboard (Gorilla @ UC Berkeley): https://gorilla.cs.berkeley.edu/
leaderboard.html
- BFCL v3 multi-turn blog: https://gorilla.cs.berkeley.edu/blogs/13_bfcl_v3_multi_turn.html
- BFCL v4 web search blog: https://gorilla.cs.berkeley.edu/blogs/15_bfcl_v4_web_search.html
- BFCL v4 format sensitivity blog: https://gorilla.cs.berkeley.edu/blogs/
17_bfcl_v4_prompt_variation.html
```

```
- EigenData (BFCL multi-turn auditing/repair, arXiv HTML): https://arxiv.org/html/
2603.05553v1
- Hammer (ICLR 2025 poster page): https://iclr.cc/virtual/2025/poster/27722
- Hammer PDF (OpenReview): https://openreview.net/pdf?id=yVQcr4qjD6
- HammerBench (ACL 2025 Findings PDF): https://aclanthology.org/2025.findings-acl.175.pdf
- SDPO project page: https://self-distillation.github.io/SDPO
- SDPO arXiv: https://arxiv.org/abs/2601.20802
- OpenClaw-RL arXiv: https://arxiv.org/abs/2603.10165
- ToolRL arXiv: https://arxiv.org/abs/2504.13958
- TRM (ICLR 2026, OpenReview): https://openreview.net/forum?id=LnBEASInVr
- TRM PDF: https://openreview.net/pdf?id=LnBEASInVr
- ToolRM / FC-RewardBench (ICLR 2026 under review, OpenReview PDF): https://openreview.net/
pdf?id=Y84gsJBTCb
```

---

1 7 8 11 ICML Poster The Berkeley Function Calling Leaderboard (BFCL): From Tool Use to Agentic Evaluation of Large Language Models
https://icml.cc/virtual/2025/poster/46593

2 ICLR Poster Robust Function-Calling for On-Device Language Model via Function Masking
https://iclr.cc/virtual/2025/poster/27722

3 openreview.net
https://openreview.net/pdf?id=DQMjemrVhe

4 17 BFCL V4 · Format Sensitivity
https://gorilla.cs.berkeley.edu/blogs/17_bfcl_v4_prompt_variation.html

5 Abstract Counterfactuals for Language Model Agents | OpenReview
https://openreview.net/forum?id=ifMZw5fm7K

6 aclanthology.org
https://aclanthology.org/2025.findings-acl.175.pdf

9 10 12 openreview.net
https://openreview.net/pdf?id=Y84gsJBTCb

13 15 SDPO: Reinforcement Learning via Self-Distillation
https://self-distillation.github.io/SDPO

14 [2603.10165] OpenClaw-RL: Train Any Agent Simply by Talking
https://arxiv.org/abs/2603.10165

16 19 EigenData: A Self-Evolving Multi-Agent Platform for Function-Calling Data Synthesis, Auditing, and Repair
https://arxiv.org/html/2603.05553v1

18 openreview.net
https://openreview.net/pdf?id=yVQcr4qjD6