ChatGPT

执行摘要

本报告基于用户提供的**draft**文件，对其中关于**Claim 2（执行反馈后验蒸馏，Execution-Feedback Posterior Distillation， 简称 EFPD）**的所有陈述、定义、假设、实验设计、度量指标和结论进行归纳，并重点评估其在“严格同预算（same-budget）”前提下的有效性。我们发现：草稿多次强调“使用执行反馈来蒸馏决策后验而非表面 token”，并主张在相同反馈预算下与 token 级别 baselines 做对照；但草稿中对各类“预算”维度的说明多有缺失，仅针对反馈信息量进行了说明。实验设计主要与 token-level 基线（如 OpenClaw/SDPO-lite）比较，缺乏标准蒸馏、自蒸馏、RLHF、Chain-of-Thought 等常见 baselines 的对照，且未严格说明各方法的计算量、数据量、推理步数等是否一致。此外，草稿尚未提供充分的统计显著性分析（如多次随机种子结果、置信区间等），对潜在的信息泄漏、过拟合缺乏检验。我们建议：草稿中多处关于 Claim 2 的表述需要限缩或改写，明确“待验证”语气，避免夸大结论；补充与标准蒸馏、RLHF、CoT prompting 等 baselines 在同预算下的对照实验；严格控制并报告所有计算与数据预算维度；以及提供充足的试验重复、置信区间与统计检验。下文按照要求分别列出 Claim 2 相关内容、同预算维度核对、基线与实验设计评估、统计分析、具体修订建议及补充实验方案，并附以 Mermaid 流程图和预算对比表。

草稿内容类别	原文陈述（节选）
定义与方法描述	“执行后反馈不再修 surface token，而是修 decision posterior，并且与 token-level hindsight 在相同 feedback budget 下做对照。”【4】(第474行)
	“从 `f_t` 构造 `q(d_t \mid s_t, f_t)`，再让 prior 去逼近 posterior。”【4】(第478行)
动机与假设	“用 execution feedback 蒸馏更好的 posterior”【3】(第138–139行)；“同样使用 feedback，但更新对象是 `decision posterior`。”【3】(第171–173行)
	“把 execution feedback 的主要作用点从 token repair 改成 decision posterior distillation，并与 token-level hindsight 做同 budget 对照。”【3】(第197行)
比较基线	“decision-level posterior 与 token-level hindsight baseline 必须使用相同 feedback budget，避免‘teacher 看得更多所以更强’。”【8】(第305行)
	“用同一 feedback budget 的 apples-to-apples 实验，证明 decision-level update 比 token-level update 更可迁移。”【3】(第175行)
假设与条件	“只有在严格对齐 feedback budget 后仍然成立，才能写成主贡献。”【4】(第476–479行)；“若要让主张 2 也被它覆盖，需要再做一个带 feedback 的 counterfactual 版本。”【8】(第381–384行)
实验设计	草稿提议“构造一个 feedback-conditioned posterior”模块，分层限制反馈预算（避免 teacher 泄漏）【8】(第293–300行)；提议在主实验中**保持feedback预算一致**【4】(第478–480行)
度量指标	草稿建议使用“可执行准确率、函数调用成功率、最终任务成功率”等基础性能指标【6】(第610–614行)，并关注迁移鲁棒性；但未具体针对 Claim 2 提出新指标。
初步结论	草稿中未给出完整实验结果，暗示“Decision-level 更新应优于 token-level 更新”（例如【3】(第175行)）；但**结论性表述尚待实验验证**，如标注为“待严格审查的主贡献候选”【4】(第476–480行)。

说明：表中引用均来自草稿文本（行号注明），总结了关于 Claim 2（EFPD）的所有原始陈述。可以看出草稿核心主张是：用执行反馈对决策后验进行蒸馏，而非仅修正 token 输出，并与 token-级别对照实验在同反馈预算下进行比较；但是这些主张都附带“**严格条件下**”的限定（如需同预算公平对照、生成功能再验证等），尚未最终确立。

同预算可比性维度核对

对于“**严格 same-budget**”可比性，需要检查模型训练和评估中可能的预算差异。主要维度及草稿情况如下：

维度	草稿是否声明	计量方式（如有）	是否对齐	潜在偏差／风险
模型参数量	未明确声明	假定使用同一模型架构（未说明细节）	可能相同	草稿未提及不同模型大小，默认为一致；若不一致则直接影响比较公平性。
训练算力（FLOPs）	未声明	无说明	未对齐	未报告训练或微调所需的浮点运算量。若 EFPD 涉及额外模块或 RL，算力可能更高。
训练步数	未声明	仅提及“微调”（如是否含 RL 步）	未对齐	草稿未说明 EFPD 和基线分别训练多少轮/步；若 EFPD 训练迭代更多，则违反同预算。
数据量	未声明	没有明确训练数据集范围或批大小	未对齐	若为 feedback 蒸馏引入新的数据（如更多执行样本），则数据量不一致。
反馈使用量	已声明	“反馈 budget”提及次数/层级限制	需对齐	草稿强调与 token-基线保持**相同反馈预算**【8】(第293–300行)；但未细化如何计数反馈量、限制层级。若未严格控制，存在隐含额外信息。
推理步数（Token 长度）	未声明	未说明是否限制生成长度	未对齐	若两个模型生成token数不同，算力和反馈解读不等，也应纳入预算。
外部模型调用	未声明	未提及是否调用其他模型/工具	未对齐	若 EFPD 训练中调用执行环境或辅助模型次数更多，则属于额外预算。
并行度 / 硬件	未声明	无说明	未对齐	不同模型若在不同硬件或并行策略下运行，实际时间和能耗不同。草稿未控制。
提示长度	未声明	未提及prompt大小	未对齐	若实验使用不同提示长短，可能影响模型性能；草稿未说明。

总体来看，**草稿仅对“反馈信息预算”有所关注**，要求与 token-baseline 保持一致；但对其他维度（如参数量、训练FLOPs、数据量等）均无说明。未声明等同，则默认不对齐，这可能导致**潜在的算力或信息泄露偏差**。原则上，为保证公平比较，需要明确每一维度的预算，如训练迭代次数、RL 采样轮数、数据集大小与提示

长度等都要一致（或报告出来）[1]。例如，若 EFPD 训练加入 RL 校准，则应与 token-baseline 一起做同样规模的RL训练，否则“EFPD+RL”相比“token+RL”的效果差异可能源于不同训练预算。

实验设计与基线对照评估

草稿目前规划的对照主要是“token-level hindsight 基线”（如 OpenClaw/SDPO-lite）和部分工具适应（Hammer/CoLA-lite）。**但为了严格在同预算下验证 EFPD 的有效性，以下基线同样必要：**

- **标准知识蒸馏（Standard Distillation）**：即直接蒸馏完整模型输出，无执行反馈。参考经典蒸馏方法[2]。
- **自蒸馏 / SDPO**：如 SDPO（Lambert et al. 2025）的 on-policy 自蒸馏[3]或类似 OpenClaw（Agarwal 2024）。草稿已部分包含 token-hindsight 版 SDPO。
- **RLHF**：使用奖励模型+PPO 的方法（如 InstructGPT[4]）。草稿使用了部分 RL校准，但未与公开 RLHF 方法对比。
- **Chain-of-Thought 提示（CoT prompting）**：无需训练，仅用提示词引导推理，对一些任务能显著提升准确率[5]。
- **从零开始微调（Scratch Fine-tuning）**：直接用相同数据和预算训练模型，检验 EFPD 是否比简单多训练有效。

在下表中，对比列出了各方法的预算构成（如参数量、训练步骤、额外信息源）与预期结果指标。由于原稿未给出实际数值，此处以“一致”或“未指定”示例表示需要声明或测量的部分。

方法	参数量（大小）	训练步数 / FLOPs	反馈信息调用	外部执行次数	并行/硬件	主要结果指标
Token-level 基线	同模型	同步多轮训练（未指明数值）	与EFPD 相同预算	需要执行环境反馈（如代码执行）	同硬件	可执行准确率 / 成功率
EFPD（无 RL）	同模型	同批次训练 + 蒸馏 (未指明)	与基线相同	同基线	同硬件	预期更高迁移能力
EFPD + RL	同模型	EFPD训练 + PPO(未知迭代数)	与基线相同	增加RL环境交互	同硬件	最高准确率（假设）
标准蒸馏	同模型	SFT训练 + 蒸馏 (未指明)	无（或仅 token）	-	同硬件	比较基线效能
自蒸馏 (SDPO)	同模型	多次自推断 + 蒸馏 (Lambert 2025)	rich feedback	执行环境反馈	同硬件	参考 SDPO 性能
RLHF	同模型	SFT + PPO (大规模训练)	人类标注奖励模型	-	同硬件	提升行为一致性
Chain-of-Thought 提示	n/a	仅推理，无额外训练	n/a	-	同硬件	性能改善示例 (GSM8K 提升至 SOTA)[5]
Scratch 微调	同模型	仅SFT (相同训练步)	无	-	同硬件	基准比较效果

说明：表中“训练步数/FLOPs”及“反馈信息调用”等项需要在实验报告中详细列明具体数值。若某方法涉及额外训练（如 RLHF 需 PPO 迭代、SDPO 需多轮反馈蒸馏），应计算并注明等效算力。每种方法的“外部执行次数”指调用代码/环境反馈的次数，应与反馈预算一致。我们建议在最终论文中用表格形式**明确各方法预算构成与结果对照**，确保真正“同预算比较” [1] [6]。

统计显著性与结果可靠性

草稿当前尚未给出具体实验结果，但按照科学研究要求，结果评估应包括：

- **多次实验重复与随机种子**：至少使用 3–5 个不同随机种子重复每项实验（如 Henderson et al. 建议的 5 次 [7] [8]），对比平均值和标准误差，以减少偶然性。深度RL研究常见 5 次试验 [7] [8]（部分参考 Dell Medium）甚至更多（如 Mania 等用 10–100 次 [9]）。
- **置信区间与误差条**：对每个指标报告平均值、标准差或 95% 置信区间 [6]。如可执行准确率等（离散任务可用二项分布推断 CI），误差条应在图表或表格中给出，不能只报点值。
- **显著性检验**：根据任务性质选择合适的统计检验（如两个策略表现比较可用t检验或配对Wilcoxon检验）。报告 p-value 或置信区间，说明性能差异是否显著，而非仅凭小幅变化下结论。
- **独立测试集**：使用与训练无交叉的评测数据集进行最终测试。草稿多次提到 BFCL-v3/v4 审计集，应保证决策蒸馏训练时没有使用这些测试样本，以避免过拟合泄露。对抽象 schema perturbation 任务的测试也应独立于训练 schema。
- **过拟合与泄露检查**：如草稿所述，“关键增益在经过审计子集复核后消失”即为过拟合风险。在报告中应展示训练/验证曲线，确认模型未仅记忆训练数据。如使用 RL，亦需防止奖励模型过拟合训练反馈。

综合上述，草稿需要严格按照论文投稿指南提供充分的可复现性细节 [6] [7]，目前对显著性和可靠性的论述明显不足。建议增加独立重复试验结果、置信区间或 p 值，并在图表说明中标出误差条，按照 NeurIPS 等会议规范“报告多次试验结果并附置信区间” [6] [7]。

草稿修订建议

下表指出草稿中需要**收紧、删除或重写**的句段，并给出建议替换说法（逐条对应原文片段）：

原文节选（行号）	问题描述／修订方向	建议替换或说明
“执行后反馈不再修 surface token，而是修 decision posterior…”	过于肯定，结论尚无实证支持。	改为：“初步设想利用执行反馈来蒸馏决策后验（而非修正 surface token），需通过同预算对照实验证明其有效性。”。
“用 execution feedback 蒸馏更好的 posterior”	顶层标题用语不够严谨，应说明为研究假设。	改为：“研究假设：使用执行反馈可改进决策后验的质量。”
“decision-level update 比 token-level update 更可迁移”	未说明前提条件，需补充“同预算”限定。	可写：“在相同反馈预算下，我们假设决策层面的更新比 token 级更新在模式迁移上效果更好。”
“只有在同预算公平对照和必要的 counterfactual 证据都成立后，才升格为正式主贡献”	语气恭谨，但“升格”表述不正式。	建议表述为：“目前此方法应视为待验证假设。只有在严格同预算对照和反馈驱动的对照试验支持时，才能称其为核心创新。”。
“decision-level posterior 与 token-level hindsight baseline 必须使用相同 feedback budget”	重复啰嗦，可简化说明。	简化为：“主实验中决策层后验蒸馏模型与 token-level 基线需使用相同的反馈信息量，以确保公平比较。”。

原文节选（行号）	问题描述／修订方向	建议替换或说明
“仅有 A+RL 有效，而 A-noRL 基本不成立”	表述过于绝对，应待结果验证后再决定。	改为：“如果仅含 RL 版本有效，则需重新评估决策空间方法的核心主张。”，并在正文以假设条件形式说明。
“只有 normal BFCL 提升，schema perturbation 下优势消失”	这一条为 Kill 条件，不应直接放论文主线中。	可移至讨论章节，表述为消融/评估项：“我们需验证方法在 schema 扰动（如 BFCL-v4）下仍显著优于基线。”。
图表/表格（需行号示例）	图表缺乏置信区间和显著性标注；应补充。	**图 3**（如存在）需要添加误差条和多次实验结果；**表 2**需列出各方法运行次数、种子数和统计检验结果。
…	…	…

以上修改建议强调语气谨慎、结果待验证，避免断言式主张。所有表述应明确附带**相同预算、公平对照**等前提条件。对于涉及因果关系的表述，应以**假设/结论待验证**形式出现，而非定论。例如，将“更好的 posterior”表述为“假设可改进 posterior”。此外，草稿中的图表（假设有）需要加注误差条或置信区间，并说明样本大小和种子等实验细节。

补充实验建议

为验证 EFPD 的有效性，建议增加以下对照实验及相应预算核算和评估方式：

1. **标准知识蒸馏对照**：在相同模型和数据上进行常规蒸馏（直接预测 token 或决策），计算训练 FLOPs 及反馈调用次数。指标：可执行准确率、最终任务得分。建议 5 次随机种子重复，报告均值±标准差，采用 t 检验比较与 EFPD 结果。预计额外算力≈1×（与 EFPD 相当）。[6]

2. **自蒸馏（SDPO/OpenClaw）对照**：使用当前最接近的自蒸馏方法（如 SDPO 或 OpenClaw-lite）作为 baseline，保持相同的执行反馈次数和计算预算。若使用 SDPO 的强化学习版，需加上 PPO 迭代，记录迭代步数。指标同上。重复试验并分析置信区间。额外预算≈0.5–1×（取决于 RL 迭代次数）。

3. **RLHF 对照**：训练一个奖励模型（用与数据集标注的偏好）并用 PPO 微调模型（InstructGPT方式）[4]。这模拟人类偏好对齐方案。预算：需记录训练步数、环境交互次数（PPO rollout）。指标：与人工偏好一致度、任务性能。预估额外预算较大（可能数倍），但可粗略标为“未指定”或“>>1×”，表明计算显著增多。

4. **Chain-of-Thought 提示**：对于与推理相关的任务（如BFCL模式识别），加入 CoT 提示实验[5]。无需额外训练，仅在 inference 时提供推理样例。评估：与基线模型在相同提示预算下的准确率对比。预算影响：主要为推理时的额外token消耗，标为 minimal。预期可以提升推理质量。

5. **Scratch 微调**：在与 EFPD 相同数据集和训练预算上，从头微调模型（无任何先验方法），评估是否仅靠大量训练即可达到或超越 EFPD。预算：与 EFPD 原始 SFT训练阶段相当，额外 RL 阶段不添加。结果对比同样计算显著性。

6. **反馈限定消融**：在 EFPD 实验中限制反馈信息（如只给部分反馈特征），检验 Claim 2 在弱反馈条件下的鲁棒性。预算：若反馈减半，则真实算力减少，可标为~0.5×。

7. **更多随机种子和环境多样性**：对所有实验至少 5 次随机种子，报告平均值±误差。若有可能，使用跨设备/并行化设置评测时间差异，保证平台公平。

每项补充实验均应估算所需附加算力。由于草稿未给出具体数值，可保守标示为“未指定”或依据简单推算。如 PPO 训练可能带来2-3倍 FLOPs，可在表中注明“约2×”。总之，每项新对照都应注明增加的计算或执行次数，方便读者评估可行性。

实验流程与预算流程图

以下 Mermaid 图示意草稿中提议的实验流程及各方法的预算分布：

```
flowchart TD
  数据集[(数据集)] --> 决策模型训练["决策后验模型训练（无RL）"]
  数据集 --> Token模型训练["Token-level基线训练（无RL）"]
  数据集 --> 链式提示["Chain-of-Thought 提示（无训练）"]
  数据集 --> 从零训练["从零微调训练"]

  决策模型训练 --> 决策+RL训练["决策模型+RL微调"]
  Token模型训练 --> Token+RL训练["Token基线+RL微调"]

  决策模型训练 --> 评估_EFPD["评估：EFPD 无RL"]
  决策+RL训练 --> 评估_EFPD_RL["评估：EFPD +RL"]
  Token模型训练 --> 评估_Token["评估：Token基线 无RL"]
  Token+RL训练 --> 评估_Token_RL["评估：Token基线 +RL"]
  链式提示 --> 评估_CoT["评估：CoT提示"]
  从零训练 --> 评估_Scratch["评估：Scratch微调"]
```

图中显示**各方法训练与评估流程**：同一数据集分别训练EFPD模型和token-baseline模型（均含和不含RL两种版本），以及不需训练的 CoT 提示和从零微调模型，然后在测试集上评估其性能。所有训练和评估阶段均应对比使用等量的数据和计算预算（同一反馈调用次数、相同训练轮数等），以保障公平性 [1] [6]。

预算对比表： 下表示例显示各方法在相同主训练预算下的开销对比和结果差异（数据为示意，需要实验测量）：

方法	训练步数	反馈调用次数	额外RL 迭代	主要效果
EFPD (无RL)	100K	50K	0	提高跨schema迁移性能
EFPD (+RL)	100K+20K	50K + 20K	20K PPO	最高最终任务成功率
Token-baseline (无RL)	100K	50K	0	低于EFPD的迁移性能
Token-baseline (+RL)	100K+20K	50K + 20K	20K PPO	与EFPD+RL相当
标准蒸馏 (Baseline)	100K	0	0	提供基准性能
CoT 提示	n/a	0	0	提升推理任务准确率 [5]
从零微调 (Scratch)	100K	0	0	基准对照

以上表格行应根据实际实验结果填写。注意所有方法的训练步数（和相应 FLOPs）在同一列列出；反馈调用次数需一致（如“50K”），强调“相同反馈预算”原则；若方法包含RL，额外迭代单独列出。主要效果列可填

写“可执行准确率提升”、“任务成功率”等指标差异。此表有助读者直观比较各方法在等预算条件下的贡献和结果。

参考文献： 除草稿内容外，本报告引用了机器学习领域的相关研究以指导分析，包括可复现性实验规范 [6] [7] [8]、Chain-of-Thought 提示效果 [5]、强化学习/ RLHF 概述 [4] 等。这些参考源为本报告建议提供了理论和实证支持。

---

[1] [8] [1708.04133] Reproducibility of Benchmarked Deep Reinforcement Learning Tasks for Continuous Control
https://ar5iv.labs.arxiv.org/html/1708.04133

[2] [1503.02531] Distilling the Knowledge in a Neural Network
https://arxiv.org/abs/1503.02531

[3] openreview.net
https://openreview.net/pdf?id=iEmRSwdzyw

[4] [2009.01325] Learning to summarize from human feedback
https://arxiv.org/abs/2009.01325

[5] [2201.11903] Chain-of-Thought Prompting Elicits Reasoning in Large Language Models
https://arxiv.org/abs/2201.11903

[6] Simple checklist for ML reproducibility | by Jaideep Ray | Better ML | Medium
https://medium.com/better-ml/ml-system-reproducibility-d525b4fbc7de

[7] [1709.06560] Deep Reinforcement Learning that Matters
https://ar5iv.labs.arxiv.org/html/1709.06560

[9] 强化学习实验里到底需要多少个随机种子的严格证明-腾讯云开发者社区-腾讯云
https://cloud.tencent.com/developer/article/1187799